Table of contents

1. O przedmiocie

2. Definicje, funkcje i charakterystyka komponentów SPD

3. Ocena systemów w aspektach: tworzenia modeli i analizy danych

4. Wstęp do hurtowni danych

5. Architektura systemów przetwarzania danych

6. Projektowanie, implementacja i eksploatacja baz danych

7. Projektowanie, implementacja i eksploatacja hurtowni danych

8. ETL1- ekstrakcja, transformacja i ładowanie danych

9. Przetwarzanie i optymalizacja zapytań

10. Meta dane i jakość danych

1. O przedmiocie

Forma zajęć

Wykład (30 godzin) + laboratorium (30 godzin)

Opis

Celem przedmiotu jest przede wszystkim zapoznanie studentów z pełnym cyklem tworzenia i implementacji zarówno raportów jak i kostek do analiz biznesowych , począwszy od zaprojektowania i stworzenia centralnej bazy danych, poprzez procesy ETL, budowę kostki, stworzenie środowiska analiz biznesowych, na przygotowaniu wymaganych raportów skończywszy. W ramach tego cyklu wykładów będą prezentowane podstawowe zagadnienia z zakresu projektowania i użytkowania oraz zarządzania danymi w wybranych klasach systemów, zaliczanych do grupy systemów opensourcowych jak i komercyjnych. Zagadnienia dot. tworzenia i zaprojektowania raportów i zaawansowanych analiz zostają przedstawione w laboratorium przy wykorzystaniu systemu JasperSoft oraz MSSQL server 2012 w zakresie hurtowni danych.

Wymagania wstępne

- Podstawowe wiadomości z zakresu relacyjnych baz danych i języka SQL.

Warunki zaliczenia:

Warunkiem zaliczenia przedmiotu jest wykonanie zadań spod wykładów oraz pisanie quizów zaliczeniowych. Dokładna punktacja zostanie przedstawiona w ogłoszeniach oraz w module FAQ.
Student zalicza przedmiot, jeśli otrzyma minimum połowę (50%) z zaoferowanych punktów (100%) w ramach quizów i ćwiczeń. Ostateczna ocena z przedmiotu jest wypadkową oceny z ćwiczeń i quizów.

Zawartość

- **Wykłady:**

1. Systemy analizy i przetwarzania danych – definicje, funkcje i charakterystyka komponentów.
2. Ocena systemów w aspektach: tworzenia modeli i analizy danych.
3. Architektura systemów przetwarzania danych
4. Projektowanie, implementacja i eksploatacja baz danych
5. Projektowanie, implementacja i eksploatacja hurtowni danych
6. ETL1- ekstrakcja, transformacja i ładowanie danych
7. ETL2- ekstrakcja, transformacja i ładowanie danych
8. Przetwarzanie i optymalizacja zapytań
9. Integracja, analiza i raportowanie danych
10. Meta dane i jakość danych

ćwiczenia:

1. SQL jako podstawowy język do komunikowania się z bazami danych. ćwiczenia do samodzielnego wykonania.
2. Podstawy projektowania raportów i kostek
3. Analiza bazy danych systemów transakcyjnych
4. Analiza gotowych raportów przy pomocy JasperSoft
5. Analiza gotowych kostek przy pomocy JasperSoft
6. MSSQL server - tworzenie schemat hurtowni danych na bazie istniejącej bazy danych transakcyjnej
7. Zaprojektowanie przepływów i zadania ETL
8. Ładowanie danych do hurtowni danych
9. Budowanie kostki w SQL Server
10. Podstawy tworzenia raportów w SQL Server
11. Przetwarzanie i optymalizacji zapytań

Literatura

Literatura podstawowa

1. Srrma J, (2009). "Business Intelligence - Systemy wspomagania decyzji biznesowych", Wyd. PWN, Warszawa
2. Krasowska C.A, Matejewska M.E, Lorek J. M (2013)." Podstawy hurtowni danych, Wyd. PJWZTK
3. Microsoft, SQL Server 2008 Integration Services Krok po kroku. Promise 2011
4. Ramez Elmasri, Shamkant B.Navathe, (2005) "Wprowadzenie do systemów baz danych", Helion

Literatura uzupełniająca

1. Kataryzna Z (2015), "SQL jak osiągnąć mistrzostwo w konstruowaniu zapytań", Helion T.
2. Connolly, C. Begg,(2002) "Database Systems - A Practical Approach to Design, Implementation, and Management " (third edition), Addison-

Wesley,
3. C.J. Date,(2000), " Wprowadzenie do systemów baz danych, seria „Klasyka Informatyki", Wydawnictwa Naukowo-Techniczne, Warszawa

Efekty kształcenia

Podstawowe umiejętności z użytkowania systemów informatycznych.

Student:

- zna, budowę współczesnego systemu przetwarzania danych
- zna i rozumie poszczególne transformacje danych
- unie administrować systemem przetwarzania danych
- zna zasady tworzenia i konfigurowania elementów ETL
- zna zposoby konfigurowania i cyklicznego uruchomienia pakietów
- rozumie zasady działania zaawansowanych elementów pakietów

2. Definicje, funkcje i charakterystyka komponentów SPD

Podstawowe terminy i pojęcia

dane to fakty (angielski wyraz datum wywodzi się złaciny ioznacza dokładnie fakt)

dane określona treść i struktura , nadająca się do przechowywania, przesyłania oraz wykonywania działań logicznych bądź matematycznych

z daną związana jest nazwa (ścisły identyfikator), typ danej (struktura prosta, złożona) oraz wartość

dane o najprostszej strukturze mogą przechowywać wartości numeryczne, alfanumeryczne, logiczne, datowe , multimedialne (Kilka różnych sposobów traktowania baz danych) Baza danych to

zestaw danych **model** fragmentu świata rzeczywistego

element składowy systemu informatycznego lub jego zasób

algebra BD = < D , O > gdzie struktury danych plus operacje na danych decydują o modelu danych **dane i oprogramowanie** umożliwiające dostęp do danych oraz ich zarządzanie

Definicja prawna:

Baza danych oznacza zbiór danych lub jakichkolwiek innych materiałów i elementów zgromadzonych według określonej systematyki lub metody, indywidualnie dostępnych w jakikolwiek sposób, w tym środkami elektro - nicznymi, wymagający istotnego, co do jakości lub ilości, nakładu inwestycyjnego w celu sporządzenia, weryfi - kacji lub prezentacji jego zawartości

Model danych

(pojęcie niezbyt jednoznaczne, którego znaczenie jest wypadkową takich cech)

- metajęzyk (pojęcia, terminologia) do mówienia o danych, systemach baz danych i przetwarzaniu
- sposób rozumienia organizacji danych
- języki opisu i przetwarzania danych, diagramy struktur danych, języki zapytań
- ogólne założenia dotyczące architektury systemu bazy danych
- ograniczenia, ideologie lub teorie matematyczne dotyczące struktur danych i dostępu do danych

Model danych

jako architektura systemów baz danych; obejmuje

- język definicji danych
- język operowania danymi
- więzy spójności i integralności danych
- jest odwzorowaniem istniejącej lub projektowanej struktury zbiorów informacji dla konkretnego systemu informatycznego
- zastosowany model danych w istotny sposób wpływa na przebieg projektu informatycznego oraz jego efekt końcowy – system informatyczny oparty na bazie danych

Modele baz danych

- prosty (system plików)
- relacyjny (obecnie najczęściej spotykany)
  - struktury danych są relacjami w sensie matematycznym (reprezentacja tabel)
  - przetwarzanie danych odbywa się w języku wysokiego poziomu (deklaratywny język SQL)
- relacyjno – obiektowy
- obiektowy
- semistrukturalny

Baza danych

· spójny zestaw danych i metadanych zbudowany w oparciu o model danych , na którym można wykonywać określone operacje (aspekt składniowy i operacyjny)

· reprezentuje pewien fragment świata rzeczywistego (aspekt semantyczny)

· jest projektowana, tworzona i utrzymywana z punktu widzenia przydatności dla określonych zastosowań i grupy użytkowników (aspekt pragmatyczny)

Wymagania stawiane bazą danych

· abstrakcja danych

· integralność danych

· współdzielenie danych

· bezpieczeństwo danych

· niezależność danych

· trwałość danych

System Zarządzania Bazą Danych

(Database Management System DBMS)

Zestaw oprogramowania obejmujący :

- · jądro systemu
  - gromadzenie, utrzymywanie i administrowanie masowymi zbiorami danych
  - sprawny dostęp do danych (optymalizacja pamięci i czasu dostępu do danych)
  - zarządzanie współbieżnością i spójnością (jednoczesny dostęp do danych przez wielu użytkowników)
  - bezpieczeństwo danych (autoryzacja)
- · interfejsy
  - linia poleceń
  - graficzny interfejs użytkownika
- · dodatkowo
  - środki programistyczne - API dla popularnych języków programowania
  - narzędzia dla środowisk rozproszonych

Uwagi: System Zarządzania Bazą Danych współpracuje z systemem operacyjnym; wspiera określony model danych

Użytkownicy baz danych

· administratorzy

· analitycy

· projektanci i programiści

· użytkownicy końcowi

· Interakcja z bazą danych

· interfejsy użytkownika

- prosty w trybie tekstowym (linia poleceń; interpreter języka obsługi baz danych)
- graficzny interfejs (typu BUILDER)

· aplikacje typu FORMULARZ, RAPORT i inne

Architektury komunikacyjne z systemem baz danych

- klient - serwer,
- 3 – warstwowa

Podział systemów baz danych

kryteria podziału:

- wykorzystywany model danych
- liczba węzłów / baz danych

o bazy scentralizowane

o bazy rozproszone

- cel stosowania :

o przetwarzanie transakcyjne (On – Line Transaction Processing – OLTP)

o przetwarzanie analityczne (On – Line Analytical Processing – OLAP)

o wspomaganie projektowania (Computer Aide Design – CAD)

o systemy informacji geograficznej (Geographical Information Systems – GIS)

o wytwarzanie oprogramowania (Computer Aide Software Engineering – CASE)

Systemy Zarządzania Bazą Danych komercyjne

- Oracle
- IBM - DB2
- Microsoft - SQL Server
- Sybase

niekomercyjne

- MySQL
- PostgreSQL

SQL (S tructured Q uery L anguage)

- język do obsługi baz danych
- deklaratywny
- u standaryzowany
- optymalizowany
- obejmuje

o zapytania (wyszukiwanie danych)

o tworzenie struktur danych i ich modyfikacje – DDL

o aktualizację danych – DML

o kontrolę danych - DCL

SELECT [DISTINCT] co ? FROM skąd (źródło danych) [WHERE warunek logiczny dla wierszy] [GROUP BY kryterium grupowania [HAVING warunek logiczny dla grup]] [ORDER BY [kryterium porządkowania] ;

Porządkowanie - opcja ORDER BY

Przykłady:

SELECT Nazwisko, Imiona FROM Studenci ORDER BY Nazwisko ;

SELECT Nazwisko, Data_urodzenia FROM Studenci WHERE Rok = 2 ORDER BY 2, 1 ;

SELECT Nazwisko, Rok, Gr_dziekan FROM Studenci ORDER BY Rok DESC, Gr_dziekan, Nazwisko

SELECT Nazwisko, Data_urodzenia, Trunc(Months_between(Sysdate, Data_urodzenia)/12) Wiek FROM Studenci ORDER BY Wiek DESC, 1 ; SELECT Nazwisko, Imiona FROM Studenci WHERE Rok = 3 **ORDER** BY Dbms_random.value() ;

Uwagi:

- co może być kryterium porządkowania ?
- domyślne ustawienia uporządkowania
- sposoby uporządkowania (rosnący, malejący, pseudolosowy)
- opcja ORDER BY występuje tylko raz w składni, na końcu zapytania

FUNKCJE statystyczne (agregujące związane z grupowaniem)

COUNT(*) , **COUNT**(arg) , **COUNT**(DISTINCT arg) – ilość wystąpień (zlicza)

AVG(arg_num) , **AVG**(**DISTINCT** arg_num) – średnia artymetyczna

SUM(arg_num) , **SUM**(**DISTINCT** arg_num) – suma artymetyczna (sumuje)

MIN(arg) , **MIN**(**DISTINCT** arg) – wartość minimalna

MAX(arg) , **MAX**(**DISTINCT** arg) – wartość maksymalna

Przykłady:

SELECT Count(*) FROM Studenci ;

SELECT Count(DISTINCT Gr_dziekan) FROM Studenci WHERE Rok = 3 ;

SELECT Min (Data_urodzenia), Max (Data_urodzenia) FROM Studenci ;

SELECT Rok , Count(*) FROM Studenci GROUP BY Rok ;

SELECT Imiona , Count(*) Ile FROM Studenci **GROUP BY** Imiona ORDER BY Ile DESC ;

SELECT To_char(Data_urodzenia , 'DAY'), Count(*) FROM Studenci GROUP BY To_char(Data_urodzenia , 'DAY')

3. Ocena systemów w aspektach: tworzenia modeli i analizy danych

Analityczne przetwarzanie danych

Zasadniczą ideą systemów analitycznych jest zapewnienie zarządzającym efektywnego dostępu do właściwej, wiarygodnej, dostarczanej na czas informacji w celu wspomagania podejmowania decyzji, wspierających realizację strategii organizacji.Takie systemy bazując na hurtowniach danych (ang. *Data Warehouse* – **DW**) są zdolne do **analitycznego przetwarzania danych na bieżąco** (ang. *On-Line Analytical Processing* **– OLAP**).

OLAP cechuje możliwość:

- wykonywania analiz wielowymiarowych wg złożonych kryteriów wyszukiwania,
- interaktywnego raportowania bez znajomości języków programowania,
- uzyskiwania odpowiedzi na skomplikowane i często niestandardowe (ang. *ad hoc*) zapytania w trybie bieżącym.

W architekturze OLAP wyróżniamy motory [DIN1997, GOKO1999b, BLA1998]:

- **MOLAP** (*OLAP wielowymiarowy;* ang. *Multidimensional On-Line Analytic Processing Multidimensional,*) – do prowadzania analiz wykorzystuje serwer wielowymiarowej bazy danych MDDB (ang. *Multidimensional Database*). W tej architekturze dane muszą być przechowywane wielowymiarowo, jeżeli mają być wielowymiarowo analizowane i prezentowane.
- **DOLAP** (*OLAP Desktop*)– to motor MOLAP operujący na plikach lub bazach danych zainstalowanych lokalnie, na stacjach klienta (brak serwera).
- **ROLAP** (*OLAP relacyjny**;*** ang. *Relational On-Line Analytic Processing*) – do prowadzania analiz i wielowymiarowej prezentacji korzysta z danych przechowywanych w relacyjnej bazie danych (RDB) o specjalizowanej strukturze, najczęściej gwiazdy (ang. *Star*) lub płatka śniegu (ang. *Snowflake*). Dostęp do danych jest realizowany na poziomie zwykle złożonych zapytań SQL.
- **HOLAP** (*OLAP hybrydowy;* ang. *Hybrid OLAP*) – to architektura mieszana pozwalająca użytkownikom na korzystanie (nie zawsze jednocześnie) z dwóch baz danych: wielowymiarowej lub relacyjnej. HOLAP wzbogaca architekturę OLAP o mechanizm semafora serwerów ROLAP i MOLAP.

Ze względu na sposób przechowywania i przetwarzania danych najważniejsze są dwie architektury MOLAP i ROLAP, dwie pozostałe są ich pochodnymi.

2. Architektura MOLAP

Architektura MOLAP zapewnia:

- przechowywanie danych zagregowanych i przeliczonych w postaci predefiniowanej „kostki", gotowych do zaawansowanych analiz,
- wykorzystanie możliwości MDDB na stacjach użytkowników,
- zarówno zaawansowane rozwijanie danych zagregowanych (ang. *drill data*) jak i korzystanie z gotowych raportów dzięki serwerowi MDDB,
- uzyskiwanie odpowiedzi wciąż na te same dobrze zdefiniowane i powtarzane pytania analityczne oraz brak odpowiedzi na zapytania niestandardowe.
- rozwijanie i raportowanie danych atomowych w stopniu niedostatecznym.

3. Architektura ROLAP

Architektura ROLAP została oparta o relacyjne bazy danych, które służą do przechowywania „wirtualnych kostek danych" (rysunek 2). Typowym sposobem przechowywania takich kostek danych jest schemat gwiazdy, schemat płatka śniegu lub inna wielowymiarowa struktura zorientowana.

Motor ROLAP jest warstwą logiczną, która tłumaczy żądania użytkownika na zapytania SQL. Możliwe są dwa skrajne sposoby działania:

Motor ROLAP kieruje zapytania do danych źródłowych w relacyjnych bazach danych i dokonuje niezbędnych agregacji danych oraz wykonuje obliczenia na bieżąco, by utworzyć podsumowania i przedstawić wyniki użytkownikom w wielowymiarowym formacie

W procesie **ETL** (ang. *Extraction, Transformation & Load process- **ETL**)* dane z zasobów pierwotnych są ładowane do relacyjnej hurtowni danych oraz wykonywane są niezbędne agregacje – natomiast motor ROLAP kieruje zapytania SQL do danych źródłowych i częściowo zagregowanych w relacyjnej hurtowni danych

Po zdefiniowaniu modelu hurtowni danych, dane z zasobów pierwotnych (systemów OLTP (ang. *On-Line Transactional Processing)* lub obszaru pośredniego) są ładowane do bazy relacyjnej. Jeżeli model danych wymaga tego, wykonywane są procedury agregacji danych. Następnie w celu zoptymalizowania czasu wykonywania zapytań tworzone są indeksy. Użytkownik zleca wykonanie analiz wielowymiarowych motorowi ROLAP, który dynamicznie transformuje żądanie na zapytania SQL. Zapytania są przesyłane do motoru RDBMS, przetwarzane, a rezultat wielowymiarowy zostaje zwrócony użytkownikowi**.**Obliczenia agregujące wykonywane są przez motor ROLAP i motor RDBMS (dodatkowe tablice) oraz na stacji użytkownika.

Pierwotnie SQL był projektowany dla jednowymiarowych zapytań zorientowanych transakcyjnie, a nie dla złożonych zapytań wielowymiarowych.

Architektura ROLAP musi przekroczyć te ograniczenia standardowego SQL generując wielokrotne zapytania SQL (ang. *multipass SQL*).

Podsumowanie

Generalnie architektura ROLAP cechuje się:

- organizacją danych w strukturze „gwiazdy", „płatka śniegu", „konstelacji faktów", „gwiazdy skaskadowanej" umieszczonej w relacyjnej bazie danych,
- agregacją danych w hurtowni danych lub na bieżąco,
- wykonaniem operacji transformowanych na zapytanie SQL,
- dostępem do danych sumarycznych jak i do danych szczegółowych
- szerokim zakresem realizacji zapytań wyspecyfikowanych jak i *ad hoc*.

4. Wydajność OLAP w aspekcie wymagań analitycznych

5. Skalowalność architektur OLAP

6. Wydajność zapytań w kontekście procesu ładowania danych

7. Skuteczność wielowarstwowych architektur OLAP

Tabela 1. Zasadnicza charakterystyka architektury ROLAP i MOLAP

FUNKCJONALNOŚĆ	**ROLAP**	**MOLAP**
Skalowalność	Szeroki zakres	Wąski zakres
• **Złożoność modelu** ◦ **Fakty, [wymiary]** ◦ **Atrybuty** ◦ **Dane atomowe**	Bez ograniczeń	Ograniczona liczba (0 – 10) [(0 – 15)] mocno ograniczone
• **Struktura danych** ◦ **wielkość bazy danych** ◦ **struktura danych**	od 50 GB do > 10 TB Gwiazda/Płatek śniegu/ Konstelacja faktów/Inne	1 – 50 GB Kostka/ Kaskada kostek
• **Stosowalność**	Hurtownie Centralne i tematyczne	Hurtownie tematyczne i oddziałowe
Zarządzanie	Bardzo złożone	Proste
• **Mechanizmy wzrostu efektywności**	Indeksacja i agregacja Partycjonowanie	Zarządzanie podsumowaniami
• **Przenośność**		
Projektowanie	Czasochłonne	Szybkie
• **Modele**	Konceptualny Logiczny Fizyczny Mapowanie modeli	Konceptualny Deklaracja wymiarów, hierarchii, reguł kalkulacyjnych
• **Optymalizacja**	Model fizyczny	Kompresja danych
WYDAJNOŚĆ	Zróżnicowana	Stała
• **Dostęp do danych**	Transfery bloków danych	Operacje [select]
• **Zagregowanych**	Zróżnicowana	Wysoka, stała
• **Szczegółowych**	Zróżnicowana	Niska, stała

• **Optymalizacja**	Motor ROLAP (Wieloprzejściowy SQL, Zmaterializowane Widoki) Serwer RDBMS Serwer analityczny (DSS)	Motor MOLAP Serwer wielowymiarowej bazy danych
• **Ekstrakcja** ◦ **Budowa agregatów** ◦ **Przetwarzanie**	Dowolny poziom Równoległe	Całkowita Wsadowe potokowe
• **Uaktualnianie**	Cyklicznie lub „na bieżąco”	Jednorazowa ekstrakcja
• **Odtwarzanie**	Redo, Desin-Resume	
BEZPIECZEŃSTWO		
• **Wielodostęp**	Blokowanie, RDBMS	
• **Niezawodność**	Klastry (aplikacje, BD) Maszyny SMP i MPP	
Motory OLAP	Information Advantage, Informix (RedBrick, MetaCube), IBM DB2 OLAP, Aplix TM1, Sagent, Cartesis Carat MicroStrategy, Oracle	Cognos (PowerPlay), Hyperion (Essbase, Enterprise, Pilar), Comshare Decision SAS (CFO Vision), Gentia, Aplix iTM1, PWC

4. Wstęp do hurtowni danych

Systemy transakcyjne a systemy analityczne

- **Systemy transakcyjne:**

–ile pozostało niezrealizowanych zamówień,
– których produktów nie ma w magazynie,
–jaki jest stan konkretnego zamówienia,
–ilu klientów mamy obecnie,

- **Systemy analityczne:**

–które produkty cieszą się coraz większą, a które coraz mniejszą popularnością, w rozbiciu na kategorie,
–jakie kategorie produktów są sezonowe,
–którzy klienci prawdopodobnie niebawem zamierzają zrezygnować z naszych usług.

CO TO JEST HURTOWNIA DANYCH

- B. Inmon, 1992:

Hurtownia danych to zbiór

- zintegrowanych,
- nieulotnych,
- zróżnicowanych czasowo
- ukierunkowanych baz danych,wykorzystywanych w systemach wspomagania decyzji.

Podstawowe cele:

- przetwarzanie analityczne danych (OLAP)
- wspomaganie decyzji (DSS)
- archiwizacja

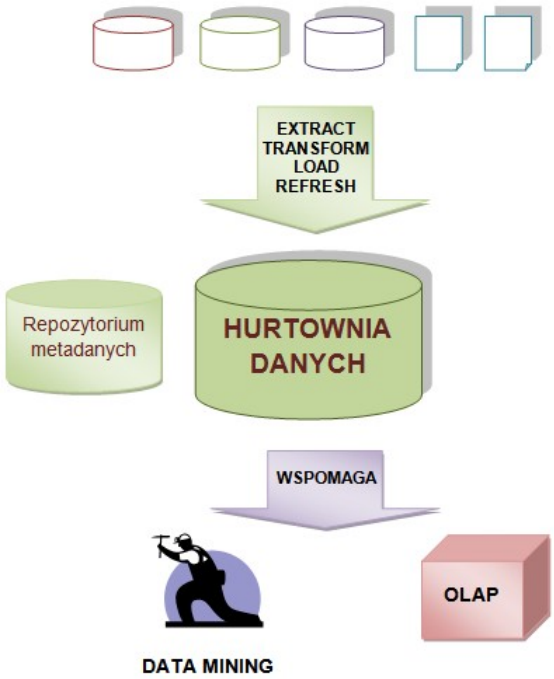

OLTP a OLAP

OLTP

on-line transaction processing przetwarzanie *transakcyjne*

- bieżąca działalność Przedsiębiorstwa
- lduża liczba prostych zapytań (fakty)

- ldodawanie, usuwanie i modyfikacja danych

- natychmiastowy dostęp do aktualnych informacji

OLAP

on-line analytical processing przetwarzanie analityczne

- Analizy, raporty
- Niewielka liczba skomplikowanych zapytań
- Odczytywanie informacji i ich cykliczne uzupełnianie
- Dane mogą być dostępne z opóźnieniem

Cele tworzenia HD

- IDSS (decision support systems)
- lTworzenie raportów

–jaka była wielkosc sprzeda(y w rozbiciu na miesiace?
–jaka grupa klientów generuje 80% obrotu?
–jaka jest struktura (histogram) wielkosci zakupów?

- Odkrywanie wiedzy (KDD, data mining)

Typowe zastosowania

- Analiza trendów i zachowań
- Wykrywanie oszustw
- Ukierunkowany marketing
- Analiza rentowności
- Zapobieganie odejściu klienta
- Zarządzanie zasobami
- .....

5. Architektura systemów przetwarzania danych

Model pojęciowy, logiczny i fizyczny. Wielowymiarowy model danych.

RODZAJE IMPLEMENTACJI

- **Architektura scentralizowan**a: fizyczna hurtownia centralna (i ew. ODS).
- **Architektura federacyjna**: hurtownia centralna jest wirtualna (perspektywy nie zawsze zmaterializowane), pobiera dane z ODS.
- **Architektura warstwowa**: fizyczna hurtownia centralna, kolejne warstwy fizycznych hurtowni tematycznych.

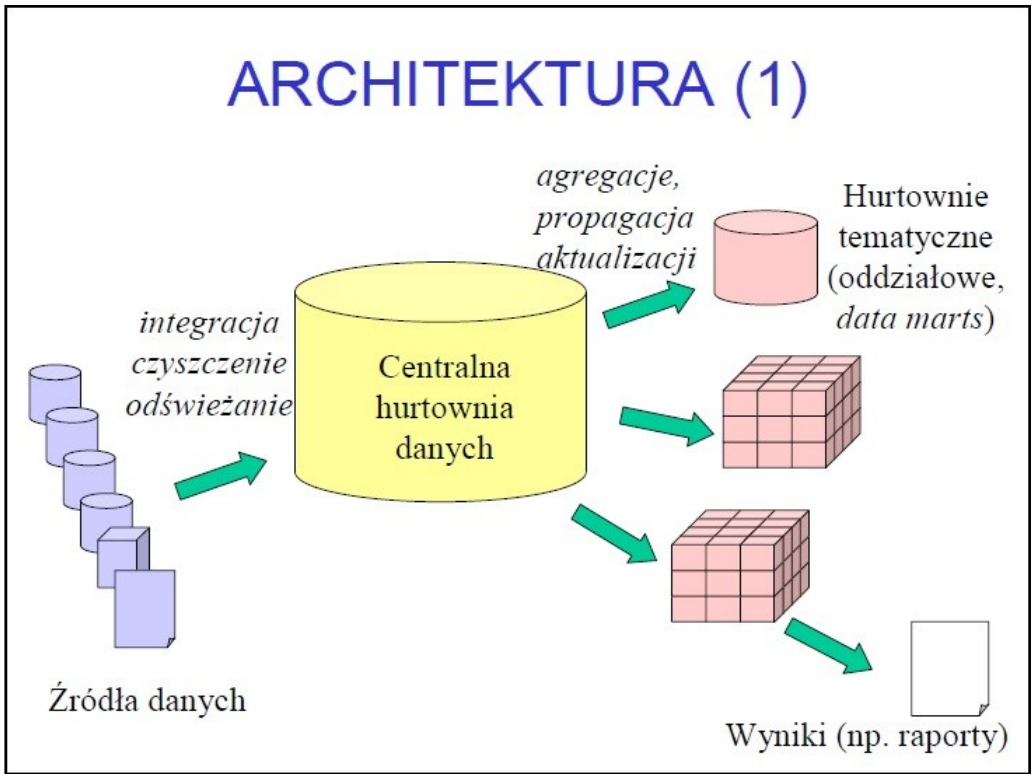

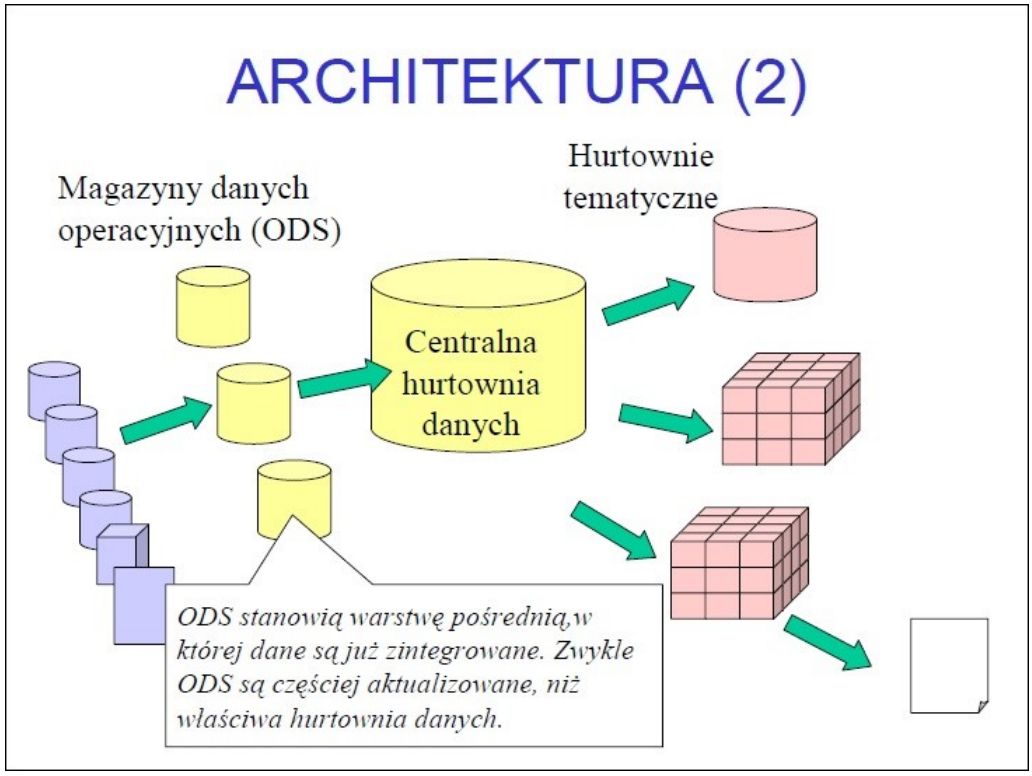

Baza zawiera **fakty** opisane przez **wymiary** i określające wartość **miar**.

Przykład:

Kostka wielowymiarowa danych

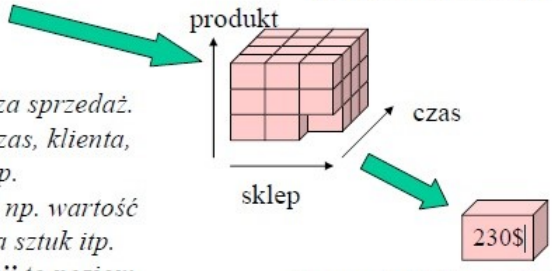

Fakt *- pojedyncza sprzedaż. Opisana przez czas, klienta, produkt, sklep itp.*
Miarą *może być np. wartość sprzedaży, liczba sztuk itp.*
Poziom agregacji *to poziom szczegółowości opisu wymiarów, np. czas można dzielić na dni lub na kwartały.*

Zawartość komórki:
zagregowana miara *(np. suma sprzedaży danego produktu w danym sklepie, danego dnia)*

SYSTEMY ZARZĄDZAJĄCE

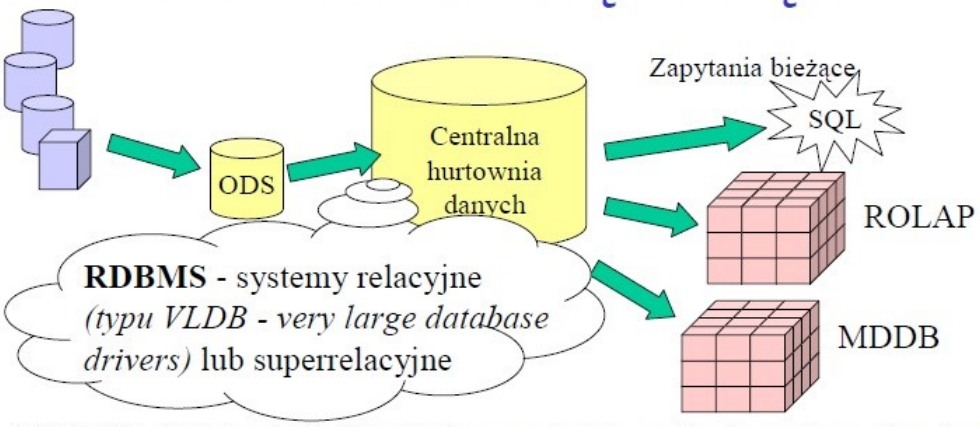

ROLAP - Relational OLAP, nakładka przesłaniająca relacyjną strukturę danych na rzecz dostępu wielowymiarowego.

MDDB - systemy zarządzające przechowujące dane bezpośrednio w postaci kostek wielowymiarowych.

Systemy superrelacyjne - dodatkowe funkcje relacyjnych baz danych ułatwiające obsługę hurtowni (wsparcie schematu gwiazdy, indeksy, formaty danych).

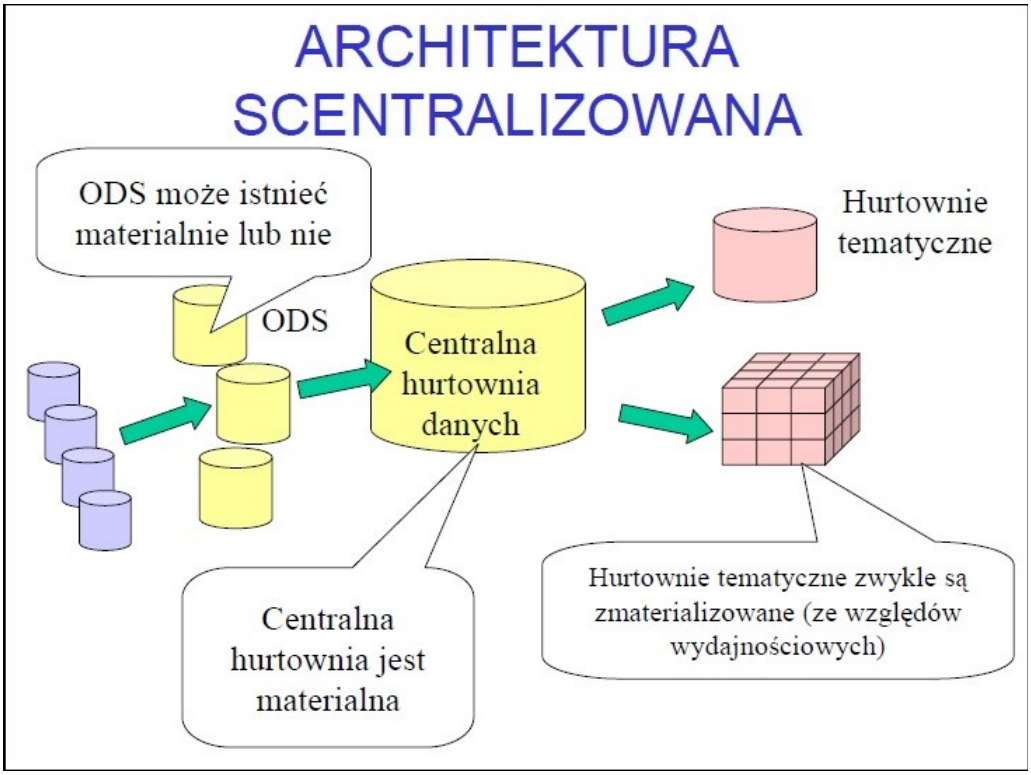
ARCHITEKTURA SCENTRALIZOWANA
ODS może istnieć materialnie lub nie
ODS
Centralna hurtownia danych
Hurtownie tematyczne
Centralna hurtownia jest materialna
Hurtownie tematyczne zwykle są zmaterializowane (ze względów wydajnościowych)

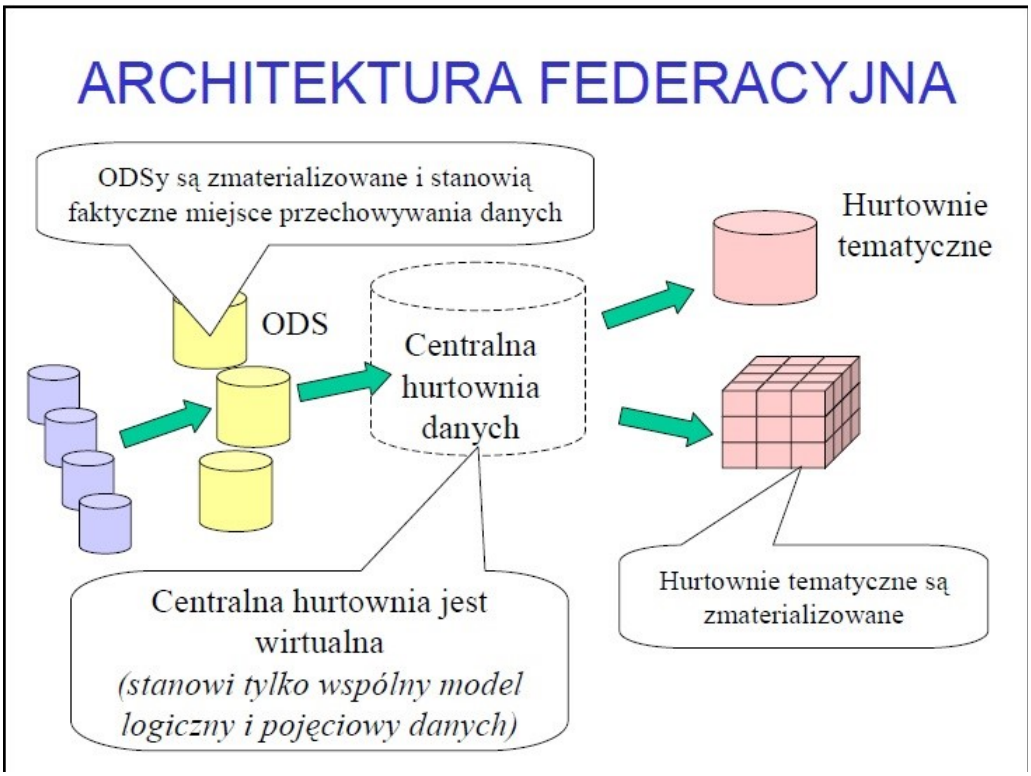
ARCHITEKTURA FEDERACYJNA
ODSy są zmaterializowane i stanowią faktyczne miejsce przechowywania danych
ODS
Centralna hurtownia danych
Hurtownie tematyczne
Centralna hurtownia jest wirtualna
(stanowi tylko wspólny model logiczny i pojęciowy danych)
Hurtownie tematyczne są zmaterializowane

ARCHITEKTURA WARSTWOWA

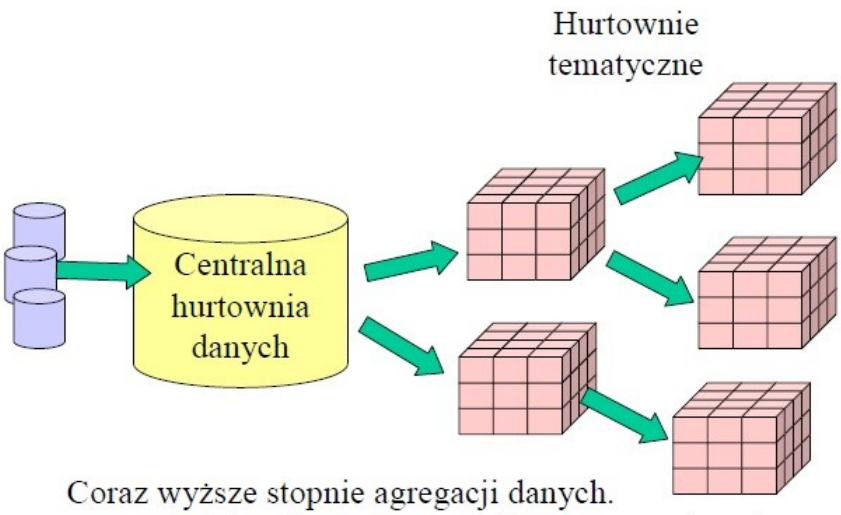

Coraz wyższe stopnie agregacji danych.
Dane z kolejnych warstw są obliczane na podstawie poprzednich. Ze względu na wydajność, wszystkie warstwy są zmaterializowane.

6. Projektowanie, implementacja i eksploatacja baz danych

Projektowanie bazy danych przechodzi przez trzy fazy:

1. *Analizę wymagań* – nie sformalizowany w pełni proces obejmujący rozmowy z grupami użytkowników, analizę aktualnie używanego środowiska operacyjnego, analizę jakie są oczekiwania jego zmiany, analizę dostępnych dokumentacji, raportów itd.

2. Tworzenie koncepcyjnego schematu bazy danych, inaczej mówiąc *modelu danych obszaru aplikacji* – opisu wysokiego poziomu danych, które mają być przechowywane w bazie danych łącznie z więzami spójności. Na tym etapie najczęściej używa się diagramów związków encji.

3. Projektowanie logicznego schematu bazy danych tj. projektowanie schematu bazy danych w terminach konkretnego systemu zarządzania bazą danych (ang. *database management system*, DBMS), w skrócie SZBD.

Omówimy pokrótce składniki diagramu związków encji, mianowicie kolejno: *encje* (ang. *entity*), *atrybuty* (ang. *attribute*) i *związki* (ang. *relationship*).

1.1 Diagramy związków encji

- Encja
- Atrybut
- Klucz (jednoznaczny identyfikator)
- Związek
- Związek binarny
- Związek rekurencyjny
- Więzy kluczowe związku
- Więzy uczestnictwa encji w związku
- Encja zależna
- Hierarchia encji (klas)
- Agregacja

1.2 Logiczny schemat bazy danych – w relacyjnej bazie danych

Rozważymy po kolei wszystkie składowe diagramów związków encji i pokażemy jak je reprezentować w relacyjnej bazie danych.

- Encja reprezentowana przez tabelę
- związek reprezentowany przez tabelę
- Związek posiadający *więzy kluczowe*
- *Encja zależna*
- *hierarchia encji*
- *Agregacja*

1.3 Dodatkowe rozszerzenia modelu ER

- *Atrybut wielowartościowy*
- *Atrybut złożony*
- *Atrybut wyliczany*

1.4 Podstawy relacyjnych języków zapytań

2. Model fizyczny bazy danych

Do tej pory zajmowaliśmy się głównie problemami modelu logicznego bazy danych. Teraz przyszła pora rozważyć szczegóły implementacji modelu logicznego w komputerze czyli szczegóły *modelu fizycznego bazy danych.*
Model fizyczny bazy danych jest oparty na pojęciach pliku i rekordu. Plik obiektu bazy danych (nazywany też segmentem tego obiektu) składa się z rekordów posiadających ten sam format. Format rekordu jest listą nazw pól z określeniem ich typów danych. Rekord składa się z wartości poszczególnych pól. Niektóre pola są wyróżnione jako klucz wyszukiwania rekordu. Może być więcej niż jeden klucz wyszukiwania rekordu. Na poziomie fizycznym nie wymaga się aby był określony jednoznaczny identyfikator (klucz) rekordu w pliku.

Podstawowymi operacjami na pliku, inicjowanymi przez programy aplikacyjne, są:

1. *Wstawianie - wstaw rekord do pliku.*
2. *Usuwanie - usuń rekord z pliku.*
3. *Modyfikacja - zmodyfikuj zawartość pól w rekordzie w pliku.*
4. *Wyszukiwanie - znajdź w pliku rekord(y) z podaną wartością klucza wyszukiwania lub spełniające podane warunki.*

2.1 Pliki rekordów

Plik stanowi kolekcję stron, z których każda zawiera zero, jeden lub więcej rekordów. Jak wiemy, na pliku są wykonywane następujące rodzaje operacji:

1. *wstawianie/usuwanie/modyfikowanie rekordu (o podanym rid),*
2. *odczytywanie konkretnego rekordu (o podanym rid),*
3. *wyszukiwanie wszystkich rekordów spełniających podane warunki.*

Jest możliwe kilka organizacji pliku rekordów. Podstawowa różnica między nimi polega na tym, czy porządkują one rekordy według wartości pewnego klucza czy nie. Najpierw rozważymy dwie organizacje zapisu nieuporządkowanego (nazywanego potocznie stertą ang. heap).

- Plik nieuporządkowany
- Plik posortowany
- Plik haszowany

3. Indeksowanie i sortowanie zewnętrzne

3.1 Indeksy

Indeks jest to struktura danych na dysku umożliwiająca szybkie wyszukiwanie danych w bazie danych na podstawie wartości klucza wyszukiwania jak np. *nazwisko osoby*. Indeks w bazie danych ma takie samo znaczenie jak skorowidz (indeks) w książce!

Indeks jest to struktura danych składająca się z *węzłów*, w których są zapisywane rekordy indeksu następujących postaci:

1. pozycje danych k^* określane względem wartości klucza wyszukiwania k. Są trzy rodzaje pozycji danych (przy czym w każdym indeksie jest stosowany tylko jeden rodzaj):
   i. sam rekord o kluczu k,
   ii. para: (k,w) gdzie k jest kluczem rekordu a w jest wskaźnikiem do rekordu o tym kluczu,
   iii. para: $(k,w_1,...,w_n)$ gdzie k jest kluczem rekordu a $w_1,...,w_n$ jest listą wskaźników do rekordów o kluczu k; pozycja danych tej postaci jest bardziej zwarta niż odpowiadający jej zbiór pozycji danych postaci (ii) ale za to wymaga zmiennej liczby pól;
2. pozycje indeksu kierujące wyznaczeniem właściwej pozycji danych k^* w oparciu o wartość klucza wyszukiwania k; pozycją indeksu może być, na przykład, para postaci (*wartość klucza*, *wskaźnik do węzła w indeksie*).

- Złożone klucze wyszukiwania
- Indeks haszowany

3.2 Sortowanie zewnętrzne - wielofazowe sortowanie przez scalanie

Sortowanie zewnętrzne to problem sortowania pliku rekordów, który nie mieści się w pamięci wewnętrznej RAM.

Metodą stosowaną w bazach danych jest *wielofazowe sortowanie zewnętrzne przez scalanie*. Algorytm składa się z dwóch etapów:

Etap 1: Tworzenie początkowych uporządkowanych bloków rekordów (ang. *run*) – za pomocą jednej z metod sortowania wewnętrznego i dystrybucja ich do dwóch lub więcej obszarów dyskowych. Oznaczmy ich liczbę przez B.
Etap 2: Wielofazowe odczytywanie obszarów dyskowych z danymi, scalanie kolejnych bloków z zapisywaniem ich do obszarów dyskowych – powtarzane dopóki nie otrzyma się pojedynczego, uporządkowanego bloku rekordów.

7. Projektowanie, implementacja i eksploatacja hurtowni danych

Wstęp

Hurtownia danych jest bardzo dużą bazą danych (często rzędu dziesiątek czy setek terabajtów). Hurtownia danych posiada następującą charakterystykę:

- dane w niej składowane nie są modyfikowane przez użytkowników, są natomiast wyłącznie przez nich odczytywane,

- zawiera wszystkie dane historyczne i bieżące,

- zawiera dane zagregowane na wielu poziomach szczegółowości,

- zawartość hurtowni jest zorientowana tematycznie, np. hurtownia danych nt. ruchu telefonicznego i opłat klientów sieci komórkowej, hurtownia danych nt. sprzedaży pojazdów.

1. Systemy komercyjne

• Oracle8i, Oracle9i, Oracle10g – Oracle Corporation,
• DB2 UDB – IBM,
• SybaseIQ – Sybase, Inc.,
• SAS Enterprise BI Server - SAS Institute
• MS SQL Server – Microsoft,
• SAP Business Warehouse – SAP,
• Adabas C i Adabas D – Software AG,
• Teradata – NCR Corporation,
• Hyperion Essbase OLAP Server – Hyperion Solutions Corporation
• Red Brick Warehouse – Red Brick System

2. Architektura hurtowni danych. Model pojęciowy, logiczny i fizyczny. Wielowymiarowy model danych.

2.1 Ogólna architektura hurtowni danych

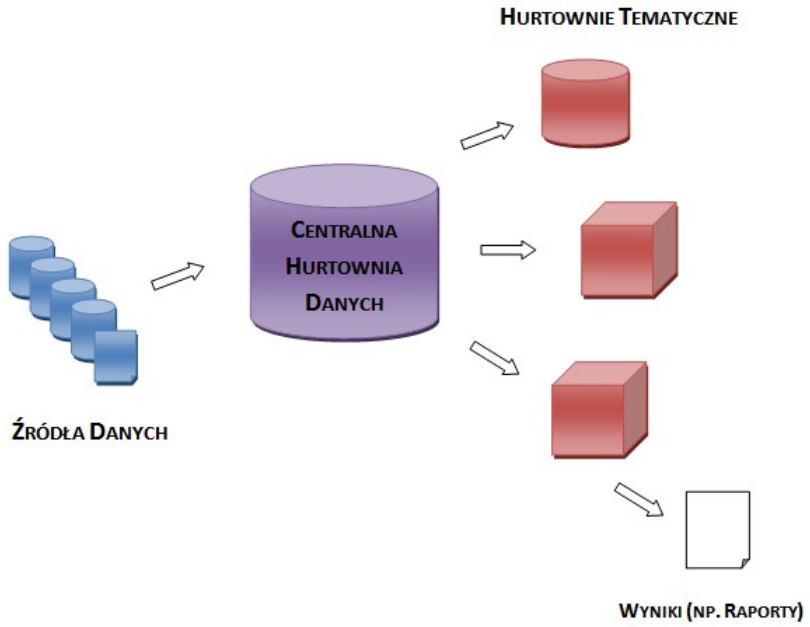

Strukturę hurtowni danych tworzą kolejne warstwy danych, przy czym każda następna warstwa jest zasilana z poprzedniej. Najniższą warstwę stanowią, bardzo często heterogeniczne i rozproszone, **źródła danych**, którymi mogą być relacyjne bazy danych (np. systemy transakcyjne), inne systemy zastane w przedsiębiorstwie, arkusze kalkulacyjne, pliki tekstowe, pliki XML, urządzenia rejestrujące itp. Źródła te mogą być bardzo zróżnicowane pod względem sposobu dostępu, a także struktury logicznej, wielkości i jakości danych.

Środkową warstwę stanowi **centralna hurtownia danych** (podstawowa, korporacyjna), która jest podstawowym miejscem przechowywania ukierunkowanej tematycznie informacji pochodzącej ze źródeł

Ponieważ w centralnej hurtowni danych gromadzone są ogromne ilości danych dotyczące działalności całej firmy, często kolejną warstwę stanowią tak zwane **hurtownie tematyczne** (data marts, hurtownie oddziałowe), tworzone na potrzeby użytkowników z konkretnych działów

Czasami między źródłami a centralną hurtownią danych wprowadza się warstwę pośrednią, zwaną **magazynem danych operacyjnych** (operational data store, ODS).

2.2 Rodzaje implementacji

W praktyce spotyka się trzy podstawowe architektury fizyczne hurtowni danych: architekturę scentralizowaną, federacyjną oraz wielowarstwową

Architektura scentralizowana

W architekturze scentralizowanej wszystkie dane wykorzystywane do analiz w przedsiębiorstwie są przechowywane w jednej fizycznej hurtowni danych, przez co najlepiej sprawdza się ona w firmach o scentralizowanej działalności operacyjnej.

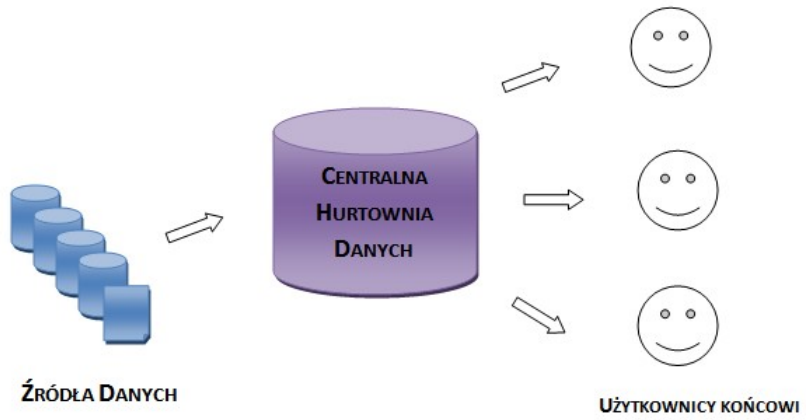

Architektura federacyjna

Architektura federacyjna to architektura rozproszona, w której logicznie jednorodne dane fizycznie przechowywane są w różnych bazach danych zlokalizowanych w jednym lub wielu systemach komputerowych. Przechowywane lokalnie tematyczne hurtownie danych zawierają informacje właściwe konkretnemu działowi danej instytucji.

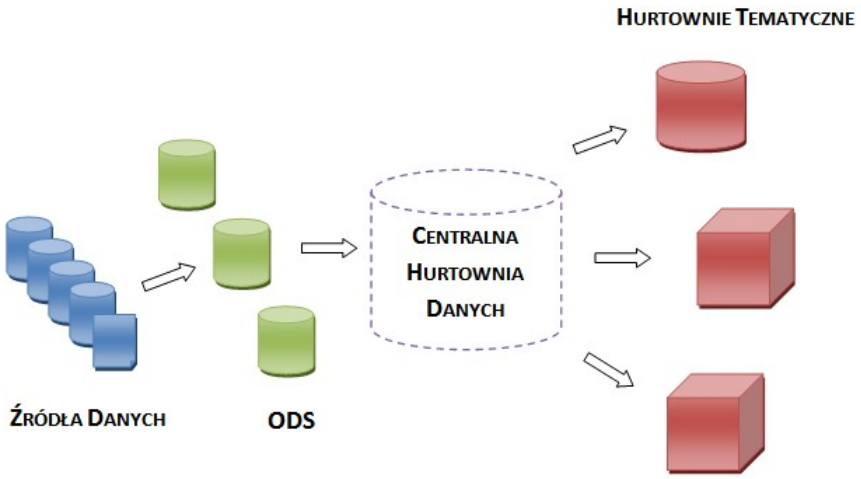

Architektura wielowarstwowa

Architektura wielowarstwowa to architektura, w której hurtownię centralną będącą rzeczywistą, fizyczną bazą danych uzupełniają kolejne poziomy lokalnych tematycznych hurtowni danych, zawierających kopie danych poprzedniej warstwy lub ich podsumowania. Z uwagi na wydajność, wszystkie warstwy są materializowane.

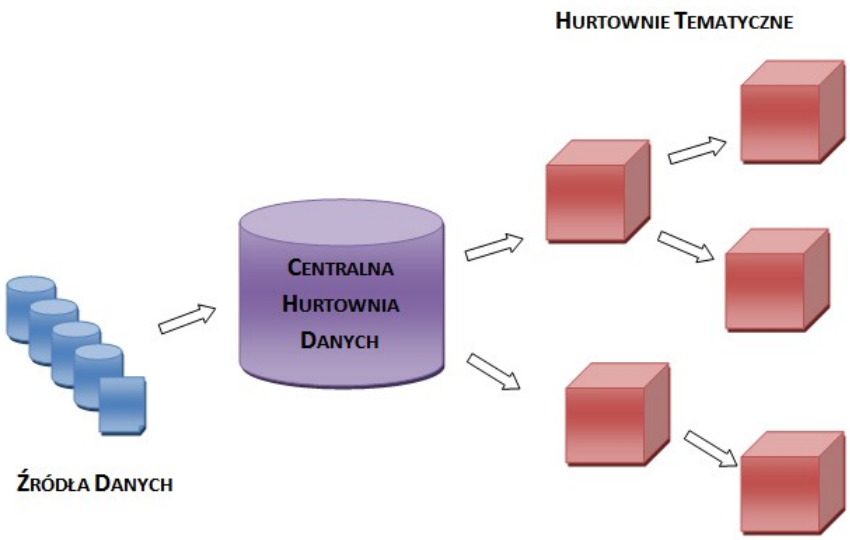

3. Model pojęciowy, logiczny i fizyczny

Poszczególne modele można scharakteryzować następująco:

- **Model pojęciowy** to opis struktury, zawartości i przeznaczenia hurtowni danych z punktu widzenia celów biznesowych. W opisie tym używane są często zwroty specjalistyczne, charakterystyczne dla działalności danej firmy. Na tym etapie ustalamy m. in. co chcemy analizować, jakie dane chcemy gromadzić, na jakie pytania chcemy znać odpowiedzi, jakie raporty chcemy generować. Jest to też moment do definiowania pewnych „oczywistych" pojęć takich jak „klient" lub „sprzedaż".
- **Model logiczny** tworzony na podstawie modelu pojęciowego to opis logiczny faktów, miar, wymiarów, atrybutów, hierarchii itp., w architekturze relacyjnej przyjmujący postać schematu gwiazdy, płatka śniegu lub konstelacji faktów, a w architekturze wielowymiarowej postać kostki lub kaskady kostek. Decydując się na architekturę relacyjną na tym etapie projektujemy schemat bazy danych, określając nazwy tabel, nazwy kolumn, typy danych, klucze, powiązania, ograniczenia itp. Na tym etapie tworzymy też mapę transformacji danych z systemów źródłowych do hurtowni.
- **Model fizyczny** generowany na podstawie modelu logicznego to opis parametrów mających na celu optymalizację działania hurtowni danych, takich jak indeksy, partycje, perspektywy zmaterializowane, a także takich elementów, jak formaty danych, procedury ETL, wyzwalacze, rozmieszczenie na dysku poszczególnych fragmentów danych, itp.

Modele logiczne hurtowni danych

Wybierając podejście relacyjne tworzymy schemat bazy danych o szczególnej, odzwierciedlającej tę wielowymiarowość strukturze. Mamy do wyboru strukturę gwiazdy, płatka śniegu lub konstelacji faktów.

Proces projektowania hurtowni danych powinien być ukierunkowany na spełnienie wymagań biznesowych. Proces ten składa się z czterech etapów:

1. *Określenie wymagań biznesowych, ustalenie tematu hurtowni* – zrozumienie celów i potrzeb biznesowych z uwzględnieniem posiadanych danych źródłowych.
2. *Zdefiniowanie poziomu szczegółowości (ziarnistości) danych* – określenie poziomu szczegółowości danych, do których chcemy się odwoływać z poziomu tabeli faktów (możemy np. chcieć przechowywać każdą oddzielną transakcję sprzedaży albo agregować zakupy tego samego produktu dokonane przez tego samego klienta w tym samym dniu, nawet jeśli będą pochodziły z różnych transakcji).
3. *Określenie wymiarów, atrybutów i hierarchii wymiarów* – określenie poziomu szczegółowości na ogół pokazuje nam, jakie tabele wymiarów powinniśmy przewidzieć.
4. *Określenie miar* – miary (zwane też wskaźnikami) powinny być sumowalne, a przynajmniej częściowo sumowalne.

Schemat gwiazdy

Ustaliwszy temat analiz, wymiary analizy oraz miary w sposób bezpośredni obrazujemy to na tak zwanym **schemacie gwiazdy** (star schema).

W naszym przykładzie schemat gwiazdy wyglądałby następująco:

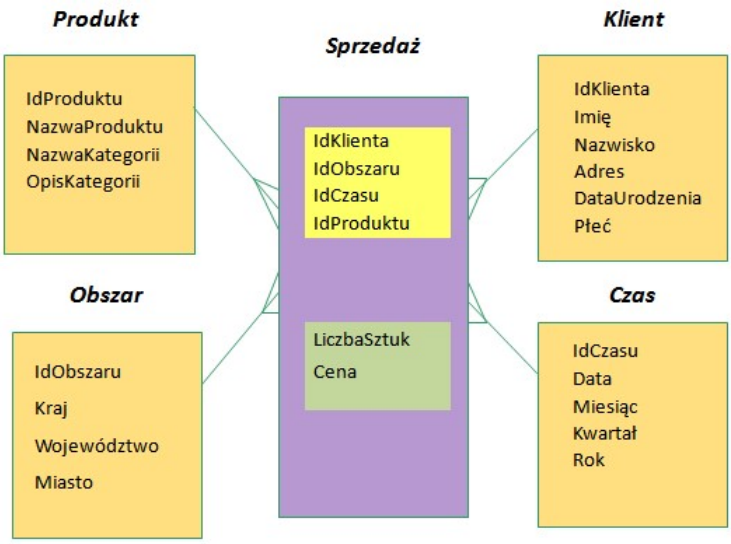

W centrum schematu gwiazdy znajduje się tabela faktów, w której przechowywane są pojedyncze zdarzenia będące podstawą analiz. Zdecydowana większość zapytań zadawanych do hurtowni będzie odwoływała się do tabeli faktów. W naszym przykładzie tabelą faktów jest tabela ***Sprzedaż***.

Schemat płatka śniegu

Czasami niektóre tabele wymiarów dodatkowo normalizuje się uzyskując schemat nazywany **płatkiem śniegu** (snowflake schema). Schemat płatka śniegu dla naszego przykładu:

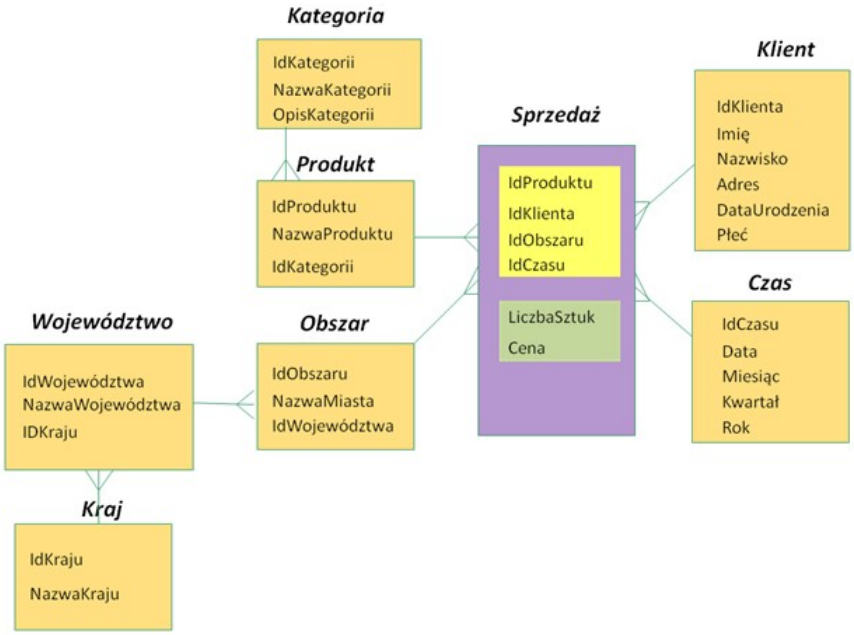

Schemat konstelacyjny

Tworząc hurtownię danych możemy się też spotkać z sytuacją, gdy chcemy przechowywać różne rodzaje faktów. Wówczas mamy możliwość stworzenia tak zwanego schematu konstelacyjnego (konstelacji faktów), w którym mamy wiele tabel faktów, a pewne wymiary są współdzielone:

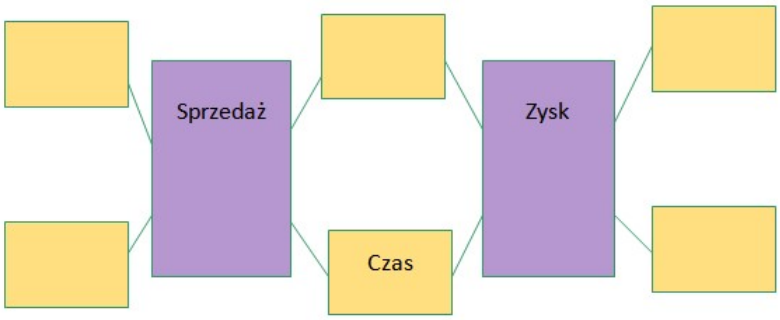

Przykład tworzenia schematu hurtowni na podstawie wymagań

Stwórzmy teraz schemat hurtowni dla niedużego banku, działającego na terenie jednego kraju, wiedząc, że od tworzonej hurtowni danych kierownictwo oczekuje możliwości uzyskania odpowiedzi na następujące pytania:

1. Jak zmieniała się w czasie liczba operacji wykonywanych na rachunkach otwartych w poszczególnych oddziałach banku?
2. Jaki był obrót na rachunkach klientów w kolejnych miesiącach, kwartałach i latach?
3. Jaki był obrót na rachunkach klientów w poszczególnych miesiącach, kwartałach i latach, z rozbiciem na grupy wiekowe i płeć?
4. Jak przedstawia się rozkład korzystania z bankomatów (częstotliwość, średnie pobierane kwoty) w zależności od dnia tygodnia i dnia miesiąca?
5. Jaka jest zależność struktury (rodzajów) wykonywanych operacji od średniego salda danego klienta?
6. Ilu mamy klientów w poszczególnych grupach aktywności, zdefiniowanych na podstawie średniego obrotu i liczby wykonywanych miesięcznie operacji?
7. Jakie były przychody oddziałów banku z tytułu odsetek od debetu w poszczególnych miesiącach?
8. Jaki współczynnik klientów zakłada konto w swoim obszarze zamieszkania i czy to się jakoś zmienia na przestrzeni czasu?

Sytuacja jest dość nietypowa, gdyż jedynym źródłem danych, jakim dysponuje bank, jest baza transakcyjna o następującym schemacie:

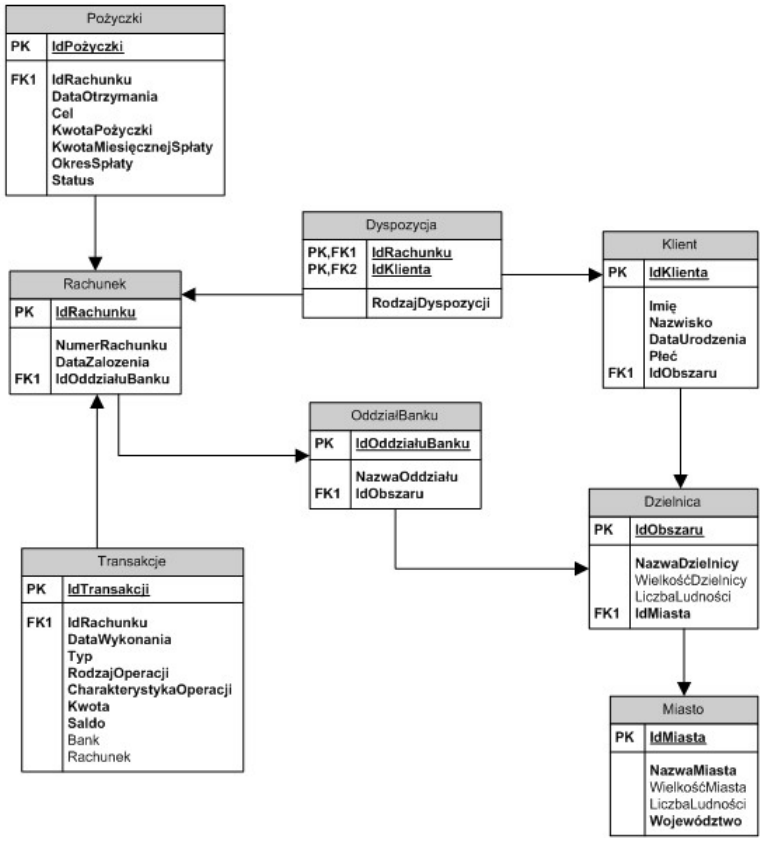

Reasumując, schemat gwiazdy tworzonej hurtowni wyglądałby tak:

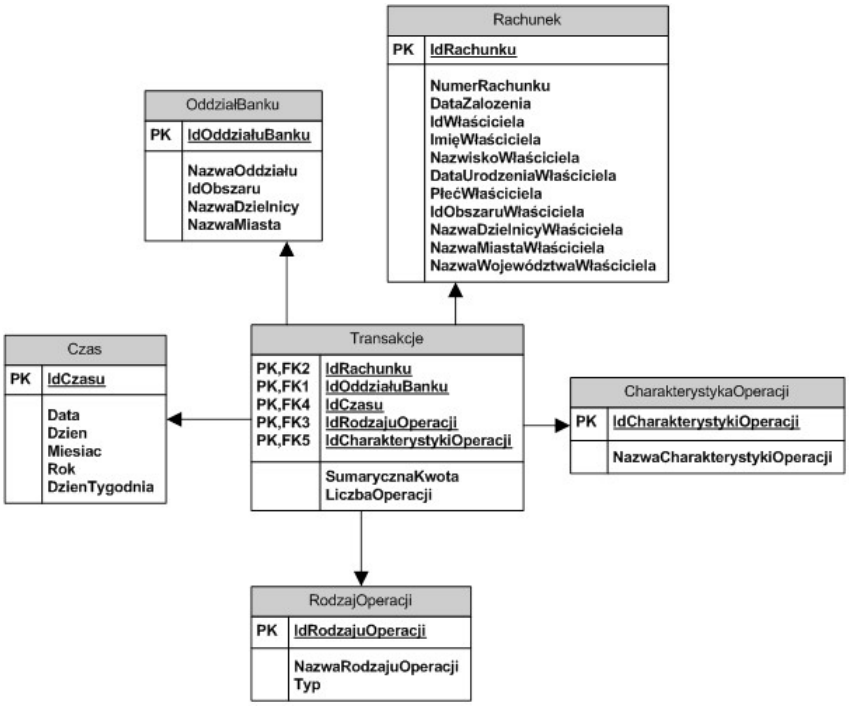

Rysunek . Proponowany schemat gwiazdy dla hurtowni danych banku

Moglibyśmy również zaproponować schemat w postaci płatka śniegu:

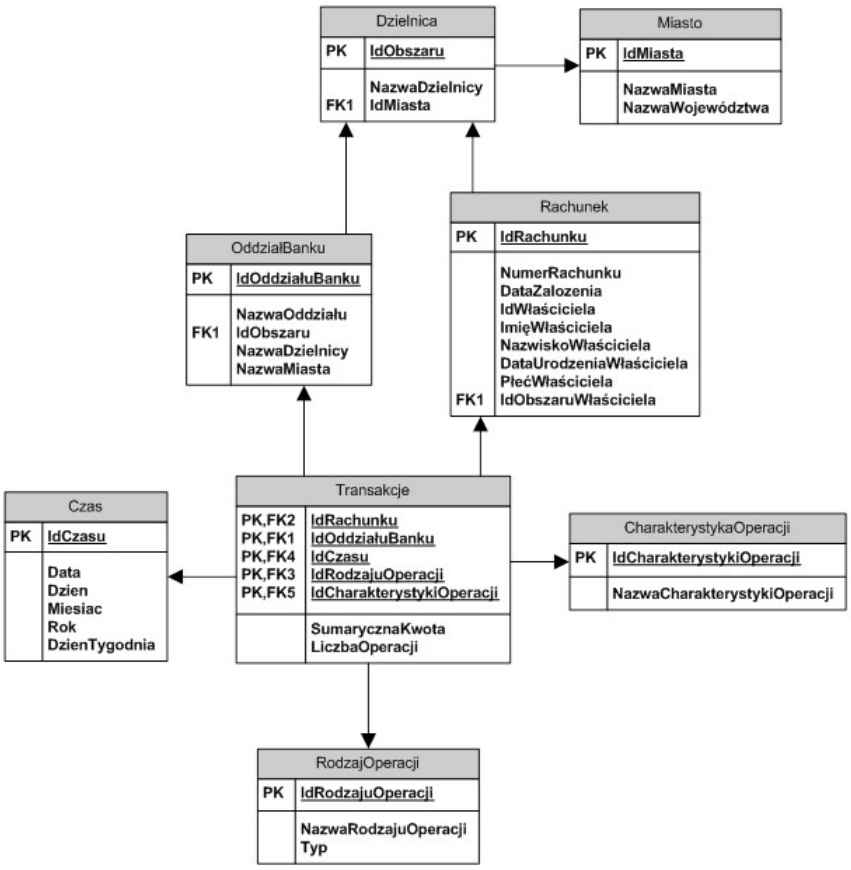

8. ETL1- ekstrakcja, transformacja i ładowanie danych

ETL – ekstrakcja, transformacja, ładowanie. Zagadnienia związane z odświeżaniem danych.

Dane typowej firmy znajdują się w wielu różnych źródłach, m. in. w:

- relacyjnych, obiektowych, hierarchicznych, sieciowych bazach danych,
- plikach tekstowych,
- arkuszach kalkulacyjnych,
- plikach XML, HTML, SGML.

Część danych może również pochodzić z urządzeń rejestrujących, ze źródeł zewnętrznych, takich jak Internet, czy bazy danych dostępne komercyjnie, a także ze źródeł bardzo szczególnych, takich jak zdjęcia, mapy, dokumenty pisane ręcznie, nagrania itp.

Zastana sytuacja wygląda zatem analogicznie do tej, przedstawionej na poniższym rysunku:

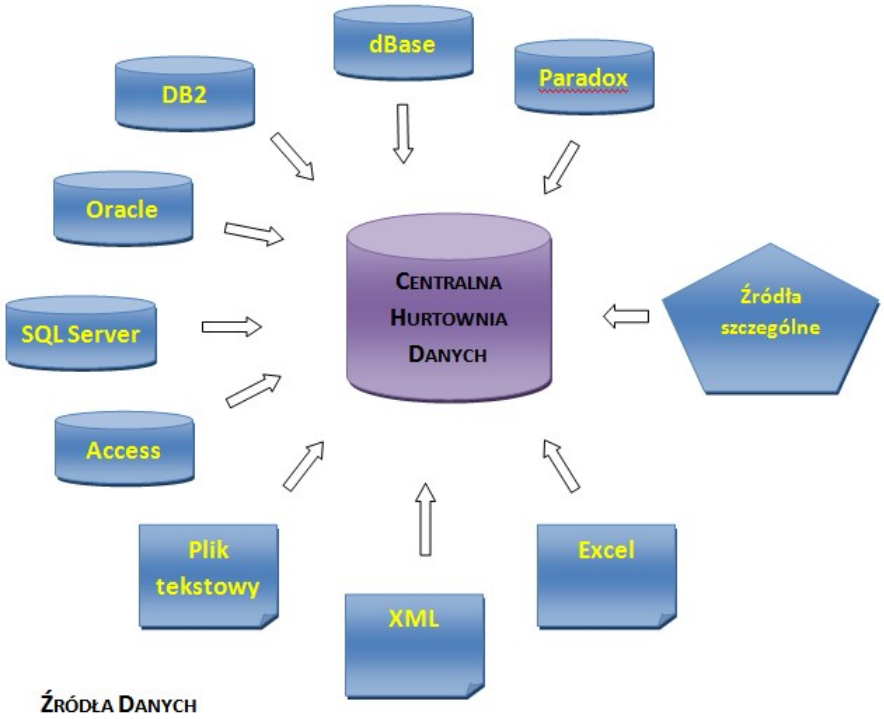

ETL – ekstrakcja, transformacja, ładowanie

Procesy przerzucania danych ze źródeł do hurtowni, czyli tak zwane procesy ETL, składają się z trzech etapów:

- ekstrakcji (Extract), czyli wydobycia danych ze źródeł,
- transformacji (Transform), czyli dostosowania treści i formatu danych do potrzeb hurtowni,
- ładowania (Load), czyli wstawienia danych do hurtowni.

Ekstrakcja

Proces ekstrakcji polega na wybraniu informacji, które mają trafić do hurtowni, a następnie pozyskaniu tych informacji z baz źródłowych. Pierwsze pytania, jakie należy sobie zadać, projektując procesy ETL, to ***co i skąd*** pobrać. Odpowiedzi na te pytania nie udzieli żadne narzędzie, musi to zrobić projektant, analizując dostępne źródła.

Transformacja

Na transformację danych składają się wszelkie operacje dostosowujące treść i format danych do potrzeb hurtowni. Są to między innymi:

- wypełnianie pustych wartości,
- zmiana formatu (daty, liczby),
- zmiana wartości (np. przeliczanie jednostek),
- ujednolicanie wartości (np. na podstawie słowników),
- utrzymanie integralności danych (więzy).

Zanim dane trafią do hurtowni muszą zostać oczyszczone, zintegrowane i odwzorowane. Przykładowo operacjami czyszczenia danych są:

- wykrywanie i (w miarę możliwości) poprawianie błędów literowych, słownikowych (błąd w nazwie miasta, których pełną listę mamy w bazie), formatu (nieistniejący numer telefonu – zbyt mało cyfr),
- wykrywanie i usuwanie niezgodności między nazwą atrybutu a zawartością (często zdarza się, że w polu Nazwa firmy jest imię i nazwisko klienta),
- normalizacja wartości, np. zamiana pustych ciągów znaków „” czy „spacji” na NULL,

Ładowanie

Ładowanie danych do hurtowni to problem przede wszystkim techniczny. Wyróżniamy trzy podstawowe metody ładowania danych:

- przekształcanie i ładowanie rekord po rekordzie – jest to najprostsza metoda ładowania danych, jednak tak mało wydajna, że trudno ją sobie wyobrazić w warunkach dużych hurtowni danych,
- zewnętrzna obróbka (scalanie, sortowanie) i ładowanie gotowych danych, często z wykorzystaniem ODS-ów,
- wykorzystanie dedykowanych, wydajnych mechanizmów docelowej bazy danych (ładowanie binarne gotowych rekordów we własnym formacie silnika hurtowni).

Tworząc hurtownię musimy rozważyć dwa rodzaje ładowania danych:

- ładowanie początkowe,
- ładowanie przyrostowe.

Ładowanie początkowe odnosi się zazwyczaj do wymiarów i historycznych faktów. Ma tę zaletę, że jest „jednorazowe” i nie musi być przeprowadzane tak rygorystycznie jak ładowania przyrostowe, gdyż w razie niepowodzenia można skasować całą partię danych i załadować od nowa. Ładowanie przyrostowe odbywa się cyklicznie (np. raz na dobę) i musi być wykonywane bardziej rygorystycznie niż ładowanie początkowe. Ładowania przyrostowe wykonywane są na ogół nocą podczas najmniejszego obciążenia hurtowni danych innymi zadaniami.

Odświeżanie danych

Omawiając procesy ETL nie sposób nie wspomnieć o zagadnieniach związanych z odświeżaniem danych, czyli z utrzymywaniem zgodności hurtowni z danymi źródłowymi. Poruszymy tu dwie kluczowe kwestie: wykrywanie zmian w danych źródłowych oraz propagację aktualizacji, czyli nanoszenie tych zmian na wszelkie potworzone materializacje np. agregacje, hurtownie tematyczne, czy kostki OLAP.

Wykrywanie zmian w danych źródłowych

Wykrywanie zmian w danych źródłowych jest zadaniem specjalnego modułu wchodzącego w skład programu ładującego – **monitora zmian**. Monitor zmian jest tym łatwiejszy do zaimplementowania, im więcej mechanizmów ułatwiających śledzenie zmian jest dostępne w systemach źródłowych.

Na poniższym rysunku znajduje się klasyfikacja źródeł danych . Źródła dzielą się na niewspółpracujące, do których zaliczamy źródła z mechanizmem migawek, odpytywane, specjalne i źródła z dziennikiem oraz współpracujące, które dzielą się na powielane i aktywne. Źródła współpracujące możemy zmodyfikować, implementując mechanizmy pozwalające odróżnianie danych już załadowanych od pozostałych

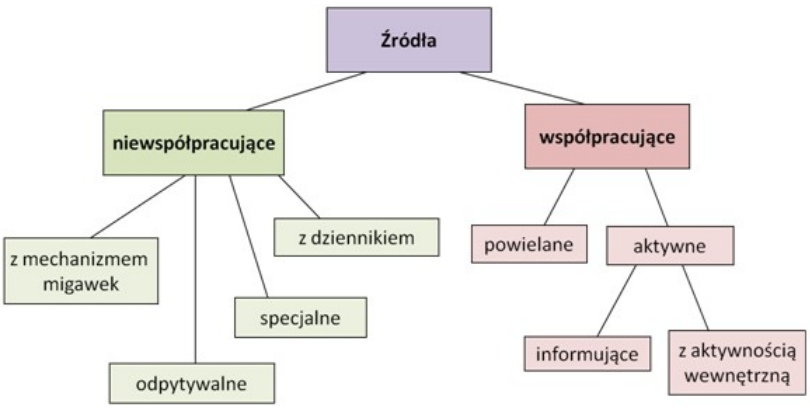

Propagacja aktualizacji

Aktualizując dane w hurtowni danych musimy pamiętać o naniesieniu tych zmian na wszelkie potworzone materializacje np. agregacje, hurtownie tematyczne, czy kostki OLAP. Pojawia się tu naturalne pytanie: kiedy powinnyśmy to robić? Są dwie strategie.

- Aktualizacja opóźniona (na żądanie, przy pierwszym użyciu po zmianie danych w hurtowni):
  - dłużej trwa pierwsze zapytanie,
  - nie musimy odświeżać tych perspektyw, których nie użyjemy.

- Aktualizacja natychmiastowa (podczas odświeżania hurtowni):
  - dłużej trwa wsadowe przetwarzanie procesu aktualizacji,
  - przerzucamy kosztowne procesy na godziny nocne,
  - część aktualizacji może okazać się zbędna.

9. Przetwarzanie i optymalizacja zapytań

Przetwarzanie i optymalizacja zapytań

Do hurtowni danych trafia wiele, często złożonych zapytań, wymagających przetworzenia bardzo dużych ilości danych, stąd priorytetową sprawą jest zapewnienie wydajnego przetwarzania tych zapytań. Zanim przejdziemy do omawiania mechanizmów poprawy wydajności, prześledźmy miejsca i rodzaje zapytań zadawanych do hurtowni.

Zapytania mogą być zadawane na zapleczu, w jądrze oraz na końcówkach.

Zapytania zadawane na zapleczu (czyli zapytania przetwarzane w źródłach, magazynach danych operacyjnych, czy programach ładujących) dotyczą na ogół ekstrakcji, przekształcania, ładowania i aktualizowania danych. Są to proste zapytania, dające w odpowiedzi duże ilości danych.

Zapytania zadawane w jądrze, czyli w centralnej hurtowni danych są na ogół złożone i przetwarzają ogromne ilości danych, zwykle zwracając relatywnie niewielki wynik (np. podsumowanie).

Zapytania zadawane na końcówkach (w narzędziach OLAP, DSS, KDD) również są złożone i zwracają relatywnie niewielki wynik w postaci podsumowania, tabeli czy raportu.

Z punktu widzenia optymalizacji zapytań istotny jest podział na zapytania predefiniowane i bieżące (ad hoc).

Zapytania predefiniowane są formułowane przez administratora i wywoływane wielokrotnie (np. dla różnych zakresów czasowych). Mają zwykle postać zapytań sparametryzowanych. Do tej kategorii należą zapytania uruchamiane na zapleczu,

Zapytania bieżące (ad hoc) są zadawane przez analityków i mają nieprzewidywalną postać. Na ogół zadaje się je na końcówkach, ale jeśli otrzymanie odpowiedzi na końcówkach jest niemożliwe, konieczne jest sięgnięcie do centralnej hurtowni.

2. Optymalizacja zapytań

Zapewnienie wydajnego przetwarzania zapytań jest w hurtowni sprawą priorytetową. Do mechanizmów poprawy wydajności, zaliczamy przede wszystkim: zrównoleglenie obliczeń, partycjonowanie, indeksowanie oraz tworzenie perspektyw zmaterializowanych.

Partycjonowanie

Partycjonowanie, zwane też podziałem, jest mechanizmem pozwalającym na rozłożenie ogromnych tabel, indeksów lub perspektyw zmaterializowanych do różnych dysków. Dzięki zastosowaniu tej metody możliwe jest:

- zrównoleglenie kosztownych operacji wejścia/wyjścia,
- zrównoleglenie wykonywania zapytań,
- przechowywanie większej ilości danych w jednej tabeli,
- łatwiejsze zarządzanie tabelami z ogromną ilością danych.

Partycje, podobnie jak indeksy, tworzone są na podstawie kluczy. Kolumna (lub kolumny) klucza wyznacza partycję, w której znajdują się dane rekordu. W SZBD spotyka się kilka sposobów tworzenia partycji:

- partycjonowanie równomierne (round-robin) – obiekt jest równomiernie rozdzielany na partycje,
- partycjonowanie zakresowe – obiekt jest dzielony na partycje na podstawie wcześniej zdefiniowanych zakresów klucza, np. miesięcy, kwartałów, czy lat,
- partycjonowanie listowe – obiekt jest dzielony na partycje na podstawie wcześniej zdefiniowanych list wartości,
- partycjonowanie haszowe – obiekt jest dzielony na partycje na podstawie wartości funkcji haszującej,
- partycjonowanie hybrydowe (partycje złożone) – obiekt jest dzielony na partycje na podstawie dwóch powyższych kryteriów (definiuje się partycje i podpartycje).

Indeksowanie

Indeks jest strukturą danych usprawniającą proces wyszukiwania danych w bazie danych na podstawie wartości klucza wyszukiwania. Indeks w bazie danych ma takie samo znaczenie jak skorowidz (indeks) w książce lub katalog w bibliotece, chociaż w pewnym sensie bardziej przypomina on konkordancję, będącą indeksem, w którym występuje każde odniesienie do każdego słowa w książce.

W hurtowni danych wykorzystuje się wiele rodzajów indeksów, między innymi:

- indeksy projekcji,
- indeksy list wartości,
- indeksy bitmapowe,
- indeksy segmentowe,
- indeksy połączeniowe.

3. Mechanizmy wspomagające działanie hurtowni dostępne w MS SQL Server

W MS SQL Server możemy tworzyć statystyki korzystając ze wszystkich danych lub jedynie z próbki. Można też tworzyć statystyki wybierając tylko te wiersze, które spełniają nałożony warunek (filtered statistics).

Statystyki tworzymy poleceniem CREATE STATISTICS:

```
CREATE STATISTICS ContactMail1
   ON AdventureWorks2008R2.Person.Person (BusinessEntityID, EmailPromotion)
   WITH SAMPLE 5 PERCENT; -- korzystamy 5% próbki danych
```

```
CREATE STATISTICS ContactMail2
   ON AdventureWorks2008R2.Person.Person (BusinessEntityID, EmailPromotion)
   WITH FULLSCAN, NORECOMPUTE;
      -- FULLSCAN = WITH SAMPLE 100 PERCENT, NORECOMPUTE
      -- bez automatycznego przeliczania
```

Partycjonowanie

Przed stworzeniem tabeli z partycjami należy najpierw stworzyć funkcję specyfikującą podział tabeli na partycje, używając polecenia CREATE PARTITION FUNCTION. Następnie należy stworzyć schemat partycji, używając polecenia CREATE PARTITION SCHEME. Partycjonowanie indeksu jest niezależne.

Przykładowo najpierw tworzymy funkcję, dzielącą tabelę bądź indeks na cztery partycje:

```
CREATE PARTITION FUNCTION Funkcja_Podziału (int)
   AS RANGE LEFT FOR VALUES (1, 100, 1000);
```

Następnie tworzymy schemat partycji, w którym definiujemy przypisanie poszczególnych partycji dzielonej tabeli bądź indeksu do grup plików:

```
CREATE PARTITION SCHEME Schemat_Podziału
   AS PARTITION Funkcja_Podziału TO (grupa1, grupa2, grupa3, grupa4);
```

Na koniec tworzymy tabelę (lub indeks) używającą danego schematu podziału (w tym przypadku na kolumnie a):

```
CREATE TABLE Nazwa_Tabeli (a int, b char(10))
   ON Schemat_Podziału (a);
```

Filtrowanie bitmapowe

Zoptymalizowane filtrowanie bitmapowe stosowane jest gdy:

- Tabela faktów ma co najmniej 100 stron (dyskowych). Mniejsze są traktowane jako wymiary.
- Między tabelą faktów a wymiarów stosowane są jedynie złączenia wewnętrzne (inner join).
- Predykat złączeniowy między tabelą faktów a wymiarów musi być dotyczyć pojedynczej kolumny, choć nie musi być złączeniem naturalnym. Preferowane są kolumny o wartościach całkowitych.
- Złączenia z wymiarów są wykorzystywane jedynie wówczas, gdy zmniejsza się liczba rozważanych wierszy.

Perspektywy zmaterializowane

Perspektywy zmaterializowane tworzymy zakładając unikatowy indeks pogrupowany na stworzonym wcześniej widoku. Nie na każdym widoku możemy założyć taki indeks. Jednym z wymagań jest konieczność użycia przy definicji perspektywy opcji WITH SCHEMABINDING. Użycie tej opcji gwarantuje, że obiekty użyte do zdefiniowania perspektywy nie zostaną usunięte ani zmodyfikowane.
Przykład tworzenia perspektywy zmaterializowanej:

```
CREATE VIEW View3 WITH SCHEMABINDING
   AS
   SELECT  ProductID,
           SUM(UnitPrice*(1.00 - UnitPriceDiscount)) AS Price,
           COUNT_BIG(*) AS Count,
           SUM(OrderQty) AS Units
   FROM Sales.SalesOrderDetail
   GROUP BY ProductID;
```

```
CREATE UNIQUE CLUSTERED INDEX iv3 ON View3 (ProductID);
```

Optymalizacja „STAR JOIN"

STAR JOIN jest metodą optymalizacji zaprojektowaną dla zapytań wykonywanych na schemacie gwiazdy. Pierwszym krokiem optymalizacji jest wykrycie wzorca gwiazdy na podstawie następujących cech:

- Największa ze złączanych tabel jest identyfikowana jako tabela faktów. Tabela ta musi mieć rozmiar większy niż określone minimum.
- Złączenia mogą być jedynie złączeniami wewnętrznymi, a predykaty złączeń muszą być równościowe i dotyczyć jednej kolumny.

Na podstawie tych cech optymalizator wykrywa schemat gwiazdy i automatycznie ustala tabelę faktów. Następnie dla każdego wymiaru występującego w zapytaniu tworzona jest tablica haszy, w oparciu o którą budowane są filtry bitmapowe. W ten sposób w dalszych operacjach bierze udział o wiele mniej wierszy.

10. Meta dane i jakość danych

Metadane i jakość danych.

1. Metadane

Każdej hurtowni danych towarzyszy **repozytorium metadanych**, czyli zbiór informacji o danych. Większość tych informacji jest zbierana automatycznie przez różne narzędzia (np. narzędzia ETL, czy system zarządzania bazą danych), choć nie wszystkie – np. o zebranie metadanych z perspektywy pojęciowej musi zadbać osoba projektująca hurtownię. Metadane są zbierane i wykorzystywane na wszystkich etapach pracy hurtowni danych, w szczególności.

- przy wybieraniu danych ze źródeł, przekształcaniu ich i ładowaniu do hurtowni są używane do odwzorowywania źródeł na wspólny model danych przyjęty w hurtowni,
- w procesie zarządzania hurtownią są wykorzystywane np. przy propagacji aktualizacji,
- przy wykonywaniu zapytań są używane do wyliczania kosztu wykonania zapytania – w szczególności do ustalenia, czy zapytanie można wykonać korzystając z dostępnych agregacji.

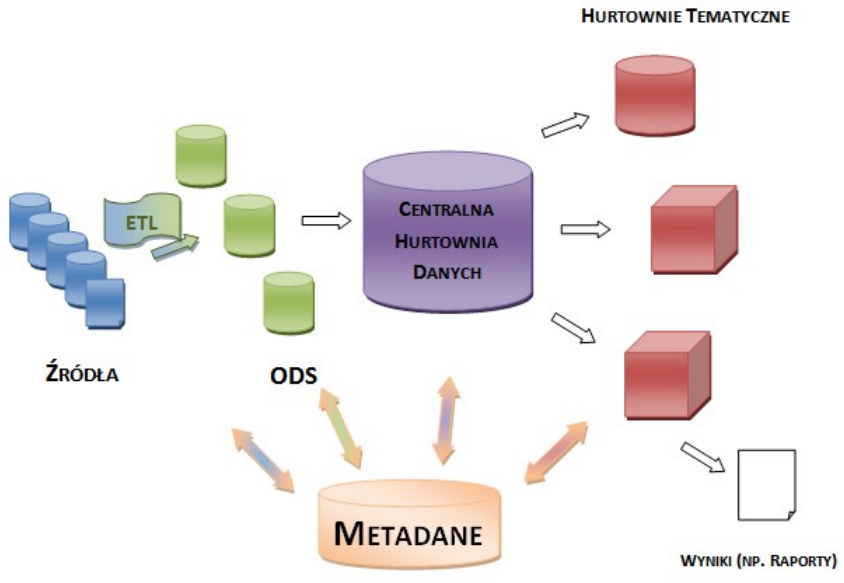

W repozytorium metadanych znajdują się:

- metadane z perspektywy pojęciowej (dane biznesowe),
- metadane z perspektywy logicznej (schemat),
- metadane z perspektywy fizycznej,
- statystyki danych,
- statystyki użycia,
- informacje administracyjne.

Metadane z **perspektywy pojęciowej** to:

- sformalizowany opis zawartości hurtowni w terminach konkretnego przedsiębiorstwa (opis gromadzonych danych, słownik pojęć, np. klient, sprzedaż, zdefiniowanie związków między różnymi pojęciami, np. klient – kontrahent),
- opis miar, wymiarów i hierarchii,
- opis pojęciowy procesu integracji danych,
- opis (biznesowy) z punktu widzenia użytkownika (np. raporty, pytania, na które chcemy znać odpowiedź itp.).

Metadane z **perspektywy logicznej** to schemat danych w centralnej hurtowni danych, źródłach i hurtowniach tematycznych, w szczególności:

- nazwy tabel i kolumn,
- typy i rozmiary danych,
- typy związków między tabelami,
- definicje więzów spójności,
- definicje perspektyw zmaterializowanych,
- definicje indeksów,
- definicje partycji,
- definicje kostek danych i hierarchii wymiarów,
- opis logiczny procesu ekstrakcji, transformacji i ładowania danych.

Metadane z **perspektywy fizycznej** to między innymi:

- definicja fizycznego rozmieszczenia danych i ich przepływu,
- informacje o lokalizacji fragmentów danych składających się na logiczne źródło danych,
- definicje agentów:
  - sterujących (np. wyzwalacze, programy powiadamiające),
  - transportowych (np. procedury ETL, procedury przeprowadzające propagację aktualizacji).

Statystyki danych są wykorzystywane podczas optymalizacji zapytań, procesów i modelu fizycznego danych. To właśnie na podstawie tych statystyk optymalizator oparty na koszcie wylicza koszt wykonania zapytania na danym planie. Do statystyk danych należą między innymi:

- rozmiary tabel,
- liczba bloków na dysku koniecznych do zapisania tabeli,
- liczba różnych wartości każdego atrybutu,
- histogramy wartości i ich częstości,
- liczba poziomów w każdym indeksie wielopoziomowym.

Gromadzenie i aktualizowanie statystyk danych jest istotne z punktu widzenia wydajności, gdyż od nich zależy działanie optymalizatora. Na niektórych serwerach statystyki są zbierane i aktualizowane automatycznie, w przypadku innych jest to zadanie administratora.

Statystyki użycia (dzienniki zapytań) pozwalają ocenić, jak często wykorzystywane są poszczególne obiekty, między innymi indeksy oraz perspektywy zmaterializowane, a także zlokalizować powtarzające się zapytania, które jeszcze nie zostały zoptymalizowane. Statystyki użycia ułatwiają administratorowi podjęcie decyzji o usunięciu niewykorzystanych obiektów oraz o dodaniu w ich miejsce takich, które nie zostały przewidziane, a ich istnienie korzystnie wpływałoby na wydajność przetwarzania zapytań.

Metadane administracyjne to między innymi:

- zasady dostępu do danych,
- definicje użytkowników i ich grup,
- terminy wykonywania cyklicznych czynności w hurtowni danych (np. ładowanie przyrostowe, backup),
- informacje o właścicielach poszczególnych danych.

2. Jakość danych

Niestety ani proces gromadzenia danych, ani ich przechowywanie nie są całkowicie wiarygodne. Szacuje się, że ilość błędów w bazach danych w różnych zastosowaniach osiąga w praktyce około 10% lub więcej.

W praktyce spotykamy się z różnymi rodzajami błędów w danych. Dane mogą być:

- brakujące,
- błędne,
- nieaktualne,
- niespójne,
- wprowadzające w błąd.

Kiedy mówimy o wartości tak subiektywnej jak jakość musimy bardzo precyzyjnie określić, co przez tę jakość rozumiemy. W ogólności potrzebujemy trzech rzeczy:

- miar jakości (nazywanych też wymiarami jakości) – co mierzymy,
- wymiernych kryteriów akceptowalności danej miary – kiedy akceptujemy,
- scenariuszy testowania – jak mierzymy.

Jest wiele prac poświęconych tematyce jakości, w których definiuje się wiele różnych miar jakości. W szczególności wśród miar jakości danych wymienia się:

- **dokładność** – procent danych o wartościach zgodnych z rzeczywistością,
- **kompletność** – procent danych o niepustych wartościach (spośród tych, które w rzeczywistości mają niepuste wartości),
- **spójność** – stopień zgodności formatów danych, np. procent wpisów niezgodnych z założonym formatem,
- **weryfikowalność** – ilość danych, których jakość można sprawdzić (procent rekordów, kolumn itp.),
- **aktualność** – procent danych, które nie są zdezaktualizowane,
- **ulotność** – procent danych o wartościach spełniających wymagania wiekowe (np. dane o zawartości magazynu mają co najwyżej dobę),
- **świeżość** – procent danych o wartościach wprowadzonych do hurtowni we właściwym czasie,
- **dostępność** – procent danych (tabel, perspektyw, kolumn) możliwych do wykorzystania przez uprawnionych użytkowników.

Na jakość danych ma wpływ między innymi jakość schematu, warto więc wspomnieć o miarach jakości schematu:

- **poprawność schematu** – rozbieżności między światem rzeczywistym a modelem pojęciowym i logicznym,
- **kompletność schematu** – zakres, w jakim model pokrywa całe przedsiębiorstwo,
- **minimalność** – prostota opisu rzeczywistości,
- **interpretowalność** – przejrzystość modelu,

- **weryfikowalność** – istnienie metod wykrywania rozbieżności.

Jakość danych w hurtowni zależy od trzech czynników:

- jakości danych wprowadzanych do hurtowni,
- budowy schematu hurtowni danych,
- przetwarzania danych w hurtowni.